## **EDA (Exploratory Data Analysis)**

#### Thực hành trên bộ dữ liệu về xe hơi

Import thư viện

In [1]: import pandas as pd import numpy as np import seaborn as sns import matplotlib.pyplot as plt

## 1. Hiểu tổng quan về bộ dữ liệu

## 1.1. Đọc dữ liệu từ file csv và hiển thị 5 dòng dữ liệu đầu tiên

In [2]: # Dọc dữ liệu từ file csv df = pd.read\_csv('../data/cars\_data.csv', header=0, delimiter=',', encoding='utf-8')

In [3]: # Hiển thị 5 dòng dữ liệu đầu tiên df.head(5)

Out[3]:

	Make	Model	Year	Engine Fuel Type	Engine HP	Engine Cylinders	Transmission Type	Driven_Wheels	Number of Doors	Ma
0	BMW	1 Series M	2011	premium unleaded (required)	335.0	6.0	MANUAL	rear wheel drive	2.0	Tun
1	BMW	1 Series	2011	premium unleaded (required)	300.0	6.0	MANUAL	rear wheel drive	2.0	Luxu
2	BMW	1 Series	2011	premium unleaded (required)	300.0	6.0	MANUAL	rear wheel drive	2.0	
3	BMW	1 Series	2011	premium unleaded (required)	230.0	6.0	MANUAL	rear wheel drive	2.0	Luxu
4	BMW	1 Series	2011	premium unleaded (required)	230.0	6.0	MANUAL	rear wheel drive	2.0	
4										•

#### 1.2. Hiển thị 5 dòng dữ liệu cuối cùng

In [4]: # Hiển thị 5 dòng dữ liệu cuối cùng df.tail(5)

Out[4]:

	Make	Model	Year	Engine Fuel Type	Engine HP	Engine Cylinders	Transmission Type	Driven_Wheels	Nı I
11909	Acura	ZDX	2012	premium unleaded (required)	300.0	6.0	AUTOMATIC	all wheel drive	
11910	Acura	ZDX	2012	premium unleaded (required)	300.0	6.0	AUTOMATIC	all wheel drive	
11911	Acura	ZDX	2012	premium unleaded (required)	300.0	6.0	AUTOMATIC	all wheel drive	
11912	Acura	ZDX	2013	premium unleaded (recommended)	300.0	6.0	AUTOMATIC	all wheel drive	
11913	Lincoln	Zephyr	2006	regular unleaded	221.0	6.0	AUTOMATIC	front wheel drive	
4									•

#### 1.3. Hiển thị kiểu dữ liệu của từng cột

## In [5]: df.dtypes

Out[5]: Make

object Model object Year int64 Engine Fuel Type object Engine HP float64 **Engine Cylinders** float64 Transmission Type object Driven Wheels object Number of Doors float64 Market Category object Vehicle Size object Vehicle Style object highway MPG int64 int64 city mpg **Popularity** int64 **MSRP** int64 dtype: object

## 2. Tiền xử lý dữ liệu

#### 2.1. Xóa đi các cột không quan tâm

Hãy xóa các cột: 'Engine Fuel Type', 'Market Category', 'Vehicle Style', 'Popularity', 'Number of Doors', 'Vehicle Size' Sau đó, hiển thị lại 5 dòng dữ liệu đầu tiên

In [6]: df.drop(['Engine Fuel Type', 'Market Category', 'Vehicle Style', 'Popularity', 'Number of Doors', 'Vehicle Size'

## Out[6]:

	Make	Model	Year	Engine HP	Engine Cylinders	Transmission Type	Driven_Wheels	highway MPG	city mpg	M:
0	BMW	1 Series M	2011	335.0	6.0	MANUAL	rear wheel drive	26	19	46
1	BMW	1 Series	2011	300.0	6.0	MANUAL	rear wheel drive	28	19	40
2	BMW	1 Series	2011	300.0	6.0	MANUAL	rear wheel drive	28	20	36
3	BMW	1 Series	2011	230.0	6.0	MANUAL	rear wheel drive	28	18	28
4	BMW	1 Series	2011	230.0	6.0	MANUAL	rear wheel drive	28	18	34
11909	Acura	ZDX	2012	300.0	6.0	AUTOMATIC	all wheel drive	23	16	46
11910	Acura	ZDX	2012	300.0	6.0	AUTOMATIC	all wheel drive	23	16	56
11911	Acura	ZDX	2012	300.0	6.0	AUTOMATIC	all wheel drive	23	16	50
11912	Acura	ZDX	2013	300.0	6.0	AUTOMATIC	all wheel drive	23	16	50
11913	Lincoln	Zephyr	2006	221.0	6.0	AUTOMATIC	front wheel drive	26	17	28

#### 11914 rows × 10 columns

In [7]: |

df.head(5)

### Out[7]:

	Make	Model	Year	Engine Fuel Type	Engine HP	Engine Cylinders	Transmission Type	Driven_Wheels	Number of Doors	Ma
0	BMW	1 Series M	2011	premium unleaded (required)	335.0	6.0	MANUAL	rear wheel drive	2.0	Tun
1	BMW	1 Series	2011	premium unleaded (required)	300.0	6.0	MANUAL	rear wheel drive	2.0	Luxu
2	BMW	1 Series	2011	premium unleaded (required)	300.0	6.0	MANUAL	rear wheel drive	2.0	
3	BMW	1 Series	2011	premium unleaded (required)	230.0	6.0	MANUAL	rear wheel drive	2.0	Luxu
4	BMW	1 Series	2011	premium unleaded (required)	230.0	6.0	MANUAL	rear wheel drive	2.0	
4										•

## 2.2. Đổi tên các cột để ngắn gọn hơn

Đổi tên các cột như sau:

"Engine HP": "HP",

"Engine Cylinders": "Cylinders",

"Transmission Type": "Transmission",

"Driven\_Wheels": "Drive Mode",

"highway MPG": "MPG-H",

"city mpg": "MPG-C",

"MSRP": "Price"

Sau đó, hiển thị lại 5 dòng dữ liệu đầu tiên

```
In [8]: df = df.rename(columns={
    "Engine HP": "HP",
    "Engine Cylinders": "Cylinders",
    "Transmission Type": "Transmission",
    "Driven_Wheels": "Drive Mode",
    "highway MPG": "MPG-H",
    "city mpg": "MPG-C",
    "MSRP": "Price"
})
```

### In [9]: df.head(5)

#### Out[9]:

	Make	Model	Year	Engine Fuel Type	НР	Cylinders	Transmission	Drive Mode	Number of Doors	Market Catego
0	BMW	1 Series M	2011	premium unleaded (required)	335.0	6.0	MANUAL	rear wheel drive	2.0	Fact Tuner,Luxury,Hi Performar
1	BMW	1 Series	2011	premium unleaded (required)	300.0	6.0	MANUAL	rear wheel drive	2.0	Luxury,Performar
2	BMW	1 Series	2011	premium unleaded (required)	300.0	6.0	MANUAL	rear wheel drive	2.0	Luxury,Hi Performar
3	BMW	1 Series	2011	premium unleaded (required)	230.0	6.0	MANUAL	rear wheel drive	2.0	Luxury,Performar
4	BMW	1 Series	2011	premium unleaded (required)	230.0	6.0	MANUAL	rear wheel drive	2.0	Lux
4										•

#### 2.3. Xử lý dữ liệu trùng lặp

## Hiển thị số dòng và số cột của bảng dữ liệu

In [10]: df.shape

Out[10]: (11914, 16)

Hiển thị các dòng dữ liệu bị trùng

```
In [11]: duplicates = df.duplicated() print(df[duplicates])
```

```
Make
            Model Year
                              Engine Fuel Type HP Cylinders \
      BMW 1 Series 2013 premium unleaded (required) 230.0
14
                                                               6.0
              100 1992
                              regular unleaded 172.0
18
     Audi
                                                       6.0
20
     Audi
              100 1992
                              regular unleaded 172.0
                                                       6.0
24
     Audi
              100 1993
                              regular unleaded 172.0
                                                       6.0
25
     Audi
              100 1993
                              regular unleaded 172.0
                                                       6.0
...
     ...
                              ... ...
                                        ...
11481 Suzuki
                X-90 1998
                                 regular unleaded 95.0
                                                         4.0
11603 Volvo
               XC60 2017
                                 regular unleaded 302.0
                                                          4.0
11604 Volvo
               XC60 2017
                                 regular unleaded 240.0
                                                          4.0
11708 Suzuki
                XL7 2008
                                 regular unleaded 252.0
                                                          6.0
11717 Suzuki
                XL7 2008
                                 regular unleaded 252.0
                                                          6.0
                    Drive Mode Number of Doors \
   Transmission
14
       MANUAL rear wheel drive
                                         2.0
18
       MANUAL front wheel drive
                                         4.0
20
       MANUAL front wheel drive
                                         4.0
24
       MANUAL front wheel drive
                                         4.0
25
       MANUAL front wheel drive
                                         4.0
...
        ...
                  ...
         MANUAL four wheel drive
                                          2.0
11481
11603 AUTOMATIC all wheel drive
                                           4.0
11604
       AUTOMATIC front wheel drive
                                            4.0
                                           4.0
11708 AUTOMATIC all wheel drive
11717 AUTOMATIC front wheel drive
                                            4.0
           Market Category Vehicle Size Vehicle Style MPG-H MPG-C \
14
          Luxury, Performance
                                Compact
                                             Coupe
                                                     28
                                                          19
18
                 Luxury
                          Midsize
                                       Sedan
                                               24
                                                    17
20
                 Luxury
                          Midsize
                                       Sedan
                                               24
                                                    17
24
                 Luxury
                           Midsize
                                       Sedan
                                               24
                                                    17
25
                 Luxury
                          Midsize
                                       Sedan
                                               24
                                                    17
11481
                    NaN
                           Compact
                                       2dr SUV
                                                  26
                                                       22
11603 Crossover, Luxury, Performance
                                     Midsize
                                                4dr SUV
                                                           29
                                                                20
             Crossover, Luxury
                                           4dr SUV
                                                      30
11604
                                Midsize
                                                           23
11708
                 Crossover
                             Midsize
                                        4dr SUV
                                                  22
                                                        15
11717
                 Crossover
                             Midsize
                                        4dr SUV
                                                  22
                                                       16
   Popularity Price
14
        3916 31500
18
        3105 2000
20
        3105 2000
24
        3105 2000
25
        3105 2000
11481
          481 2000
11603
          870 46350
          870 40950
11604
          481 29149
11708
11717
          481 27499
```

[715 rows x 16 columns]

## Hiển thị số lượng giá trị phân biệt (khác nhau đôi một) của từng cột dữ liệu

```
In [14]:
         df.count()
Out[14]: Make
                       11914
         Model
                       11914
         Year
                      11914
         Engine Fuel Type 11911
         HP
                     11845
         Cylinders
                       11884
         Transmission
                         11914
         Drive Mode
                         11914
         Number of Doors
                          11908
         Market Category
                           8172
         Vehicle Size
                        11914
         Vehicle Style
                        11914
         MPG-H
                        11914
         MPG-C
                        11914
         Popularity
                        11914
         Price
                      11914
         dtype: int64
```

#### Xóa đi những dữ liệu bị trùng lặp

```
In [12]: df.drop_duplicates(inplace=True)
```

Hiển thị lại số lượng giá trị phân biệt (khác nhau đôi một) của từng cột dữ liệu

In [14]: df.nunique().to\_frame()

Out[14]:

	0
Make	48
Model	915
Year	28
Engine Fuel Type	10
НР	356
Cylinders	9
Transmission	5
<b>Drive Mode</b>	4
Number of Doors	3
Market Category	71
Vehicle Size	3
Vehicle Style	16
MPG-H	59
MPG-C	69
Popularity	48
Price	6049

In [15]: df.count()

Out[15]: Make

Model 11199 Year 11199 Engine Fuel Type 11196 HP 11130 Cylinders 11169 Transmission 11199 Drive Mode 11199 Number of Doors 11193 Market Category 7823 Vehicle Size 11199 Vehicle Style 11199 MPG-H 11199 MPG-C 11199 Popularity 11199 Price 11199 dtype: int64

11199

## 2.4. Xử lý dữ liệu rỗng

Hiển thị số lượng giá trị rỗng của từng cột dữ liệu

các cột có giá trị false tức là không rỗng, còn có giá trị true tức là giá trị đó rỗng

In [19]: df.isnull()

Out[19]:

	Make	Model	Year	Engine Fuel Type	НР	Cylinders	Transmission	Drive Mode	Number of Doors	Market Category	Vı
0	False	False	False	False	False	False	False	False	False	False	
1	False	False	False	False	False	False	False	False	False	False	
2	False	False	False	False	False	False	False	False	False	False	
3	False	False	False	False	False	False	False	False	False	False	
4	False	False	False	False	False	False	False	False	False	False	
11909	False	False	False	False	False	False	False	False	False	False	
11910	False	False	False	False	False	False	False	False	False	False	
11911	False	False	False	False	False	False	False	False	False	False	
11912	False	False	False	False	False	False	False	False	False	False	
11913	False	False	False	False	False	False	False	False	False	False	
11914	rows ×	16 colu	mns								

Xóa đi các giá trị rỗng, sau đó hiển thị lại số lượng giá trị phân biệt của từng cột.

In [16]: df.dropna(how='any', inplace=True)

In [17]: df

Out[17]:

	Make	Model	Year	Engine Fuel Type	НР	Cylinders	Transmission	Drive Mode	Number of Doors	
0	BMW	1 Series M	2011	premium unleaded (required)	335.0	6.0	MANUAL	rear wheel drive	2.0	F٤
1	BMW	1 Series	2011	premium unleaded (required)	300.0	6.0	MANUAL	rear wheel drive	2.0	
2	BMW	1 Series	2011	premium unleaded (required)	300.0	6.0	MANUAL	rear wheel drive	2.0	I
3	BMW	1 Series	2011	premium unleaded (required)	230.0	6.0	MANUAL	rear wheel drive	2.0	
4	BMW	1 Series	2011	premium unleaded (required)	230.0	6.0	MANUAL	rear wheel drive	2.0	
11909	Acura	ZDX	2012	premium unleaded (required)	300.0	6.0	AUTOMATIC	all wheel drive	4.0	Cro
11910	Acura	ZDX	2012	premium unleaded (required)	300.0	6.0	AUTOMATIC	all wheel drive	4.0	Cro
11911	Acura	ZDX	2012	premium unleaded (required)	300.0	6.0	AUTOMATIC	all wheel drive	4.0	Cro
11912	Acura	ZDX	2013	premium unleaded (recommended)	300.0	6.0	AUTOMATIC	all wheel drive	4.0	Cro
11913	Lincoln	Zephyr	2006	regular unleaded	221.0	6.0	AUTOMATIC	front wheel drive	4.0	
7735 rd	ows × 16	column	s							
4										•

Hiển thị lại số lượng giá trị rỗng của từng cột dữ liệu

```
In [18]: df.isna().sum()
Out[18]: Make
                       0
         Model
                       0
         Year
                      0
         Engine Fuel Type 0
         HP
         Cylinders
                       0
         Transmission
         Drive Mode
         Number of Doors
         Market Category
         Vehicle Size
                        0
         Vehicle Style
                        0
         MPG-H
                        0
         MPG-C
                        0
         Popularity
                        0
         Price
                      0
         dtype: int64
```

như vậy không còn giá trị rỗng trong từng cột

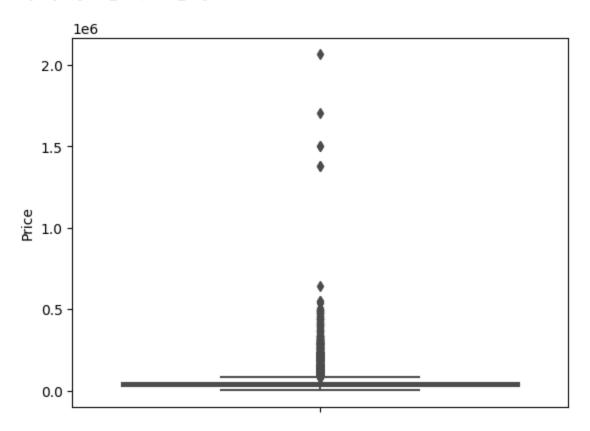
## 2.5. Xử lý outlier

Vẽ boxplot cho cột Price

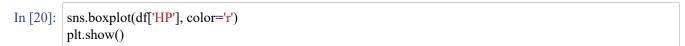
In [21]: sns.boxplot(y=df['Price'], color='r') plt.show()

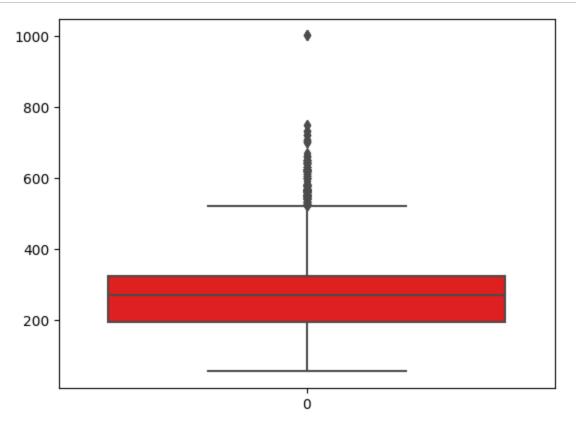
e:\LAP TRINH PYTHON\LT PTDL 1\venv\Lib\site-packages\seaborn\\_oldcore.py:1498: FutureWarning: is\_categorical\_dtype is deprecated and will be removed in a future version. Use isinstance(dtype, Categori calDtype) instead

if pd.api.types.is\_categorical\_dtype(vector):



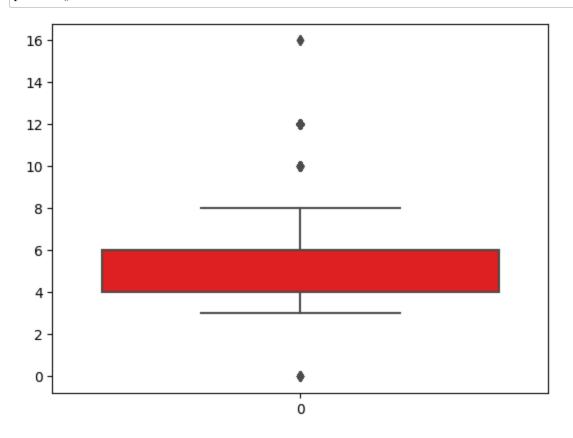
Vẽ boxplot cho cột HP





Vẽ boxplot cho cột Cylinders

In [22]: sns.boxplot(df['Cylinders'], color='r') plt.show()



In [23]: df

Out[23]:

	Make	Model	Year	Engine Fuel Type	НР	Cylinders	Transmission	Drive Mode	Number of Doors	
0	BMW	1 Series M	2011	premium unleaded (required)	335.0	6.0	MANUAL	rear wheel drive	2.0	Fŧ
1	BMW	1 Series	2011	premium unleaded (required)	300.0	6.0	MANUAL	rear wheel drive	2.0	
2	BMW	1 Series	2011	premium unleaded (required)	300.0	6.0	MANUAL	rear wheel drive	2.0	ı
3	BMW	1 Series	2011	premium unleaded (required)	230.0	6.0	MANUAL	rear wheel drive	2.0	
4	BMW	1 Series	2011	premium unleaded (required)	230.0	6.0	MANUAL	rear wheel drive	2.0	
				•••			•••			
11909	Acura	ZDX	2012	premium unleaded (required)	300.0	6.0	AUTOMATIC	all wheel drive	4.0	Cro
11910	Acura	ZDX	2012	premium unleaded (required)	300.0	6.0	AUTOMATIC	all wheel drive	4.0	Cro
11911	Acura	ZDX	2012	premium unleaded (required)	300.0	6.0	AUTOMATIC	all wheel drive	4.0	Cro
11912	Acura	ZDX	2013	premium unleaded (recommended)	300.0	6.0	AUTOMATIC	all wheel drive	4.0	Cro
11913	Lincoln	Zephyr	2006	regular unleaded	221.0	6.0	AUTOMATIC	front wheel drive	4.0	
7735 rd	ows × 16	column	ıs							
4										•

```
In [24]:
          df.dtypes
Out[24]: Make
                          object
          Model
                          object
          Year
                         int64
          Engine Fuel Type object
                        float64
          HP
          Cylinders
                          float64
          Transmission
                            object
          Drive Mode
                             object
          Number of Doors
                              float64
          Market Category
                              object
          Vehicle Size
                            object
          Vehicle Style
                            object
          MPG-H
                            int64
          MPG-C
                            int64
          Popularity
                            int64
          Price
                         int64
          dtype: object
 In [25]:
         df['Year'].dtype
Out[25]: dtype('int64')
          Tìm độ trải giữa (IQR) của từng cột dữ liệu
          for col in df.columns:
 In [26]:
            if df[col].dtypes in ('int64','float64'):
               iqr = df[col].quantile(0.75) - df[col].quantile(0.25)
               print('Độ trải giữa của cột',col,'là',iqr)
          Đô trải giữa của côt Year là 6.0
          Độ trải giữa của cột HP là 131.0
          Độ trải giữa của cột Cylinders là 2.0
          Độ trải giữa của cột Number of Doors là 2.0
          Đô trải giữa của cột MPG-H là 8.0
          Độ trải giữa của cột MPG-C là 6.0
          Độ trải giữa của cột Popularity là 1489.0
          Độ trải giữa của cột Price là 23252.5
 In [27]:
          Q1, Q3 = df['Price'].quantile([0.25, 0.75])
          IQR = Q3 - Q1
          print("Độ trải giữa (IQR) của cột Price")
          print(IQR)
```

23252.5

Độ trải giữa (IQR) của cột Price

```
In [28]: Q1, Q3 = df['HP'].quantile([0.25, 0.75])
IQR = Q3 - Q1
print("Độ trải giữa (IQR) của cột HP")
print(IQR)

Độ trải giữa (IQR) của cột HP
131.0

In [29]: Q1, Q3 = df['Cylinders'].quantile([0.25, 0.75])
IQR = Q3 - Q1
print("Độ trải giữa (IQR) của cột Cylinders")
print(IQR)

Độ trải giữa (IQR) của cột Cylinders
```

Loại bỏ đi outlier

2.0

```
In [30]: #Xác định giá trị Q1 và Q3 của cột Price
Q1, Q3 = df['Price'].quantile([0.25, 0.75])
IQR = Q3 - Q1

#Tính toán giá trị lower bound và upper bound
lower_bound = Q1 - 1.5 * IQR
upper_bound = Q3 + 1.5 * IQR

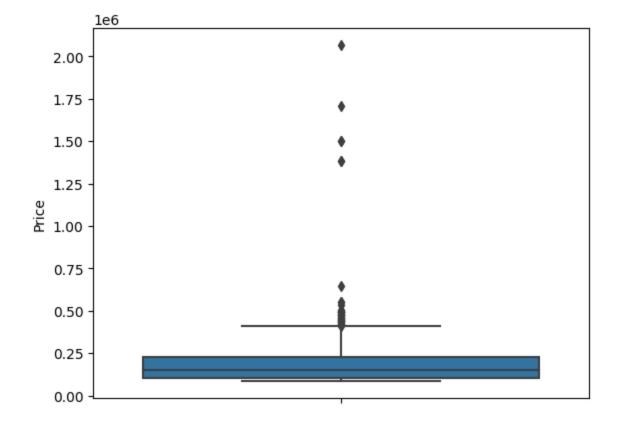
#Loại bỏ các giá trị nằm ngoài lower bound và upper bound
df = df.loc[df['Price'] >= lower_bound]
df = df.loc[df['Price'] >= upper_bound]

#Vẽ biểu đồ boxplot
sns.boxplot(data=df, y='Price')
```

e:\LAP TRINH PYTHON\LT PTDL 1\venv\Lib\site-packages\seaborn\\_oldcore.py:1498: FutureWarning: is\_categorical\_dtype is deprecated and will be removed in a future version. Use isinstance(dtype, Categori calDtype) instead

if pd.api.types.is categorical dtype(vector):

Out[30]: <Axes: ylabel='Price'>



```
In [39]:

for col in df.columns:

if df[col].dtypes in ('int64', 'float64'):

q1 = df[col].quantile(0.25)

q3 = df[col].quantile(0.75)

iqr = q3-q1

lower_bound = q1 - 1.5 * iqr

upper_bound = q3 + 1.5 * iqr

# print('Độ trải của cột',col,'là',iqr)

# df = df[df[col].between(lower_bound,upper_bound)]

df = df.loc[df[col] >= lower_bound]

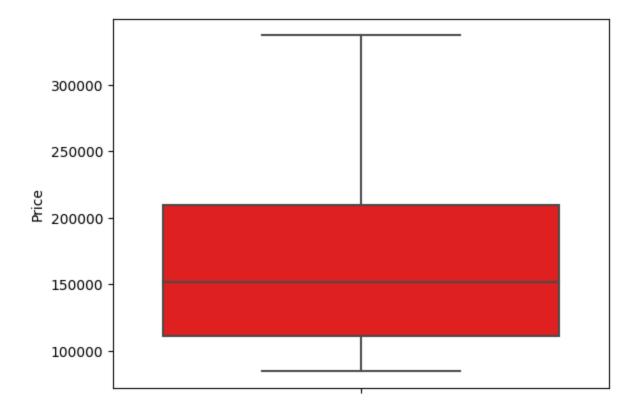
df = df.loc[df[col] <= upper_bound]
```

```
In [40]: sns.boxplot(y=df['Price'], color='r')
```

e:\LAP TRINH PYTHON\LT PTDL 1\venv\Lib\site-packages\seaborn\\_oldcore.py:1498: FutureWarning: is\_categorical\_dtype is deprecated and will be removed in a future version. Use isinstance(dtype, Categori calDtype) instead

if pd.api.types.is\_categorical\_dtype(vector):

#### Out[40]: <Axes: ylabel='Price'>

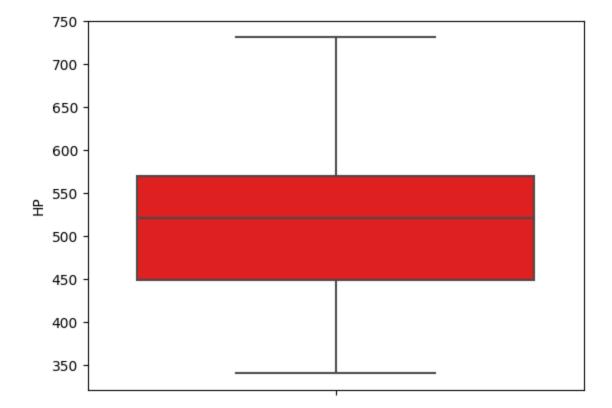


In [41]: sns.boxplot(y=df['HP'], color='r')

e:\LAP TRINH PYTHON\LT PTDL 1\venv\Lib\site-packages\seaborn\\_oldcore.py:1498: FutureWarning: is\_categorical\_dtype is deprecated and will be removed in a future version. Use isinstance(dtype, Categori calDtype) instead

if pd.api.types.is categorical dtype(vector):

Out[41]: <Axes: ylabel='HP'>

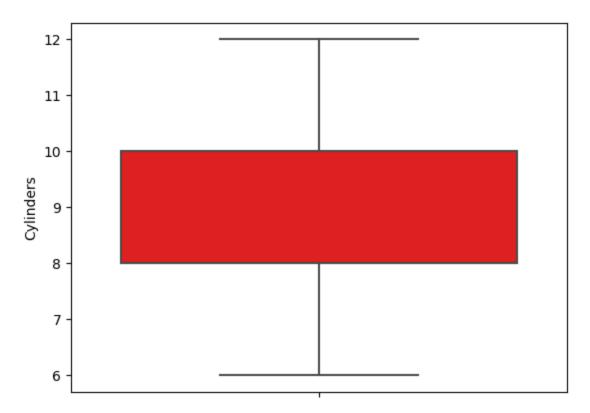


In [42]: sns.boxplot(y=df['Cylinders'], color='r')

e:\LAP TRINH PYTHON\LT PTDL 1\venv\Lib\site-packages\seaborn\\_oldcore.py:1498: FutureWarning: is\_categorical\_dtype is deprecated and will be removed in a future version. Use isinstance(dtype, Categori calDtype) instead

if pd.api.types.is categorical dtype(vector):

Out[42]: <Axes: ylabel='Cylinders'>

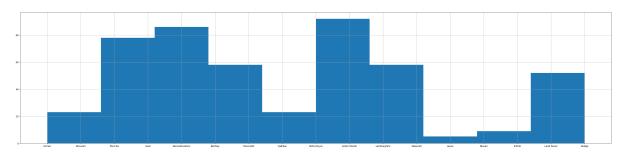


## 3. Trực quan hóa dữ liệu

#### 3.1. Vẽ histogram cho cột Make



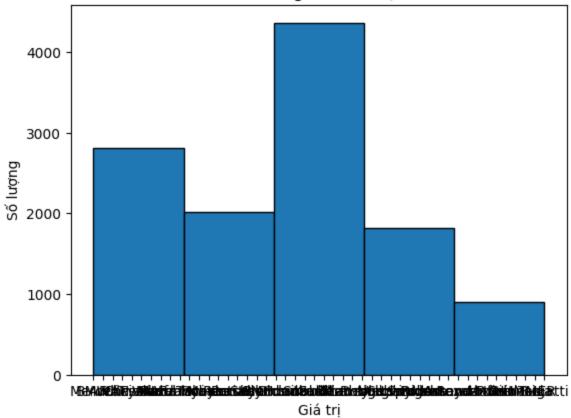




```
In [27]: # Cách 1: Sử dụng Matplotlib
```

```
plt.hist(df['Make'], bins=5, edgecolor='k')
plt.title('Biểu đồ histogram cho cột Make')
plt.xlabel('Giá trị')
plt.ylabel('Số lượng')
plt.show()
```

# Biểu đồ histogram cho cột Make



#### In [5]: # Cách 2: Sử dụng Seaborn

```
sns.histplot(data=df['Make'], bins=5, kde=True)
plt.title('Biểu đồ histogram cho cột Make')
plt.xlabel('Giá trị')
plt.ylabel('Số lượng')
plt.show()
```

e:\LAP TRINH PYTHON\LT PTDL 1\venv\Lib\site-packages\seaborn\\_oldcore.py:1498: FutureWarning: is\_categorical\_dtype is deprecated and will be removed in a future version. Use isinstance(dtype, Categori calDtype) instead

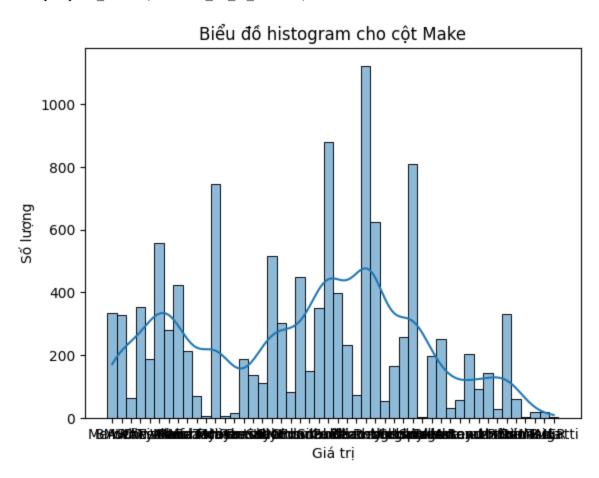
if pd.api.types.is\_categorical\_dtype(vector):

e:\LAP TRINH PYTHON\LT PTDL 1\venv\Lib\site-packages\seaborn\\_oldcore.py:1498: FutureWarning: is\_categorical\_dtype is deprecated and will be removed in a future version. Use isinstance(dtype, Categori calDtype) instead

if pd.api.types.is categorical dtype(vector):

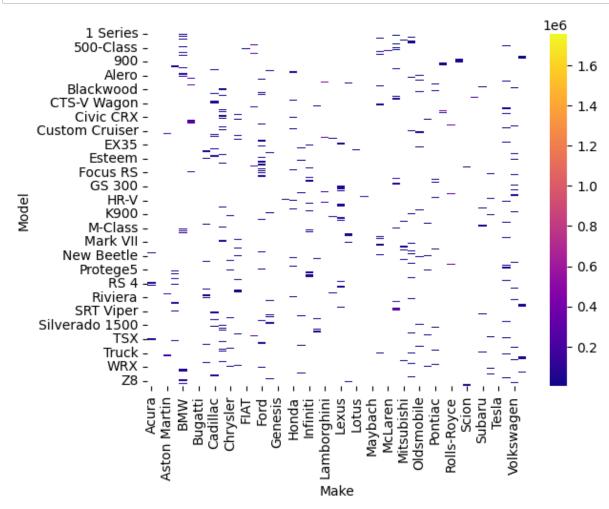
e:\LAP TRINH PYTHON\LT PTDL 1\venv\Lib\site-packages\seaborn\\_oldcore.py:1119: FutureWarning: use\_inf\_as\_na option is deprecated and will be removed in a future version. Convert inf values to NaN bef ore operating instead.

with pd.option context('mode.use inf as na', True):



#### 3.2. Vẽ biểu đồ nhiệt

In [13]: sns.heatmap(df.pivot\_table(values='Price', index='Model', columns='Make'), cmap="plasma") plt.show()



#### 3.3. Vẽ biểu đồ scatter cho 2 côt Price và HP

In [45]: plt.scatter(df['Price'], df['HP']) plt.show()

